

Omnia.AI

Подробная токен-экономика

Расчёт LLM-затрат, кошельков и маржи по тарифам
Free / Lite / Starter / Pro / Enterprise

239
платящих до break-even

-91%
ниже OPEX чем vllm plan

M11
первый плюс во 2-м месяце

9.6 M ₽
MRR на M18

1. Базовые допущения

Все расчёты в документе строятся на этих 4 параметрах. На листе «1. Параметры» XLSX-калькулятора их можно менять.

Параметр	Значение	Комментарий
Размер сообщения	8 000 токенов	5 000 input + 3 000 output. Conservative-среднее для AI-code-gen.
Output share	0.5	Половина от 1M общих токенов — output. Стандарт для chat-LLM.
Markup на токены	2.8×	Себестоимость + ~64% валовая маржа на токенах.
Курс ₽/\$	100	На 2025.

2. LLM-стек: 8 моделей

$Cost\ \text{₽/1M} = (input \times 0.5 + output \times 0.5) \times 100\ \text{₽/}\$$. $Retail = cost \times 2.8$.

Модель	Категория	Input \$/1M	Output \$/1M	Себест ₽/1M	Retail ₽/1M
DeepSeek V3.2	ультра-эконом	0.28	0.42	35 ₽	98 ₽
Qwen 3 235B (self-hosted)	ультра-эконом	0.50	0.50	50 ₽	140 ₽
Gemini 2.5 Flash	эконом	0.30	2.50	140 ₽	392 ₽
Claude Haiku 4.5	баланс	1.00	5.00	300 ₽	840 ₽
GigaChat 2 Pro	152-ФЗ	5.00	5.00	500 ₽	1 400 ₽
GPT-4.1	премиум	2.00	8.00	500 ₽	1 400 ₽
Claude Sonnet 4.6	премиум	3.00	15.00	900 ₽	2 520 ₽
YandexGPT 5 Pro	152-ФЗ премиум	8.00	16.00	1 200 ₽	3 360 ₽

3. Стоимость 1 сообщения (8 000 токенов)

Per-message cost = cost_per_M × 0.008. Retail = cost × markup.

Модель	Себест ₹/msg	Retail ₹/msg	Маржа ₹/msg	Маржа %
DeepSeek V3.2	0.28 ₹	0.78 ₹	0.50 ₹	64.3%
Qwen 3 235B (self-hosted)	0.40 ₹	1.12 ₹	0.72 ₹	64.3%
Gemini 2.5 Flash	1.12 ₹	3.14 ₹	2.02 ₹	64.3%
Claude Haiku 4.5	2.40 ₹	6.72 ₹	4.32 ₹	64.3%
GigaChat 2 Pro	4.00 ₹	11.20 ₹	7.20 ₹	64.3%
GPT-4.1	4.00 ₹	11.20 ₹	7.20 ₹	64.3%
Claude Sonnet 4.6	7.20 ₹	20.16 ₹	12.96 ₹	64.3%
YandexGPT 5 Pro	9.60 ₹	26.88 ₹	17.28 ₹	64.3%

4. Сколько стоит 50 / 200 / 1 000 сообщений

Retail-цена что заплатит пользователь. 50 msg = 400 К токенов · 200 msg = 1.6 М · 1 000 msg = 8 М.

Модель	50 сообщений	200 сообщений	1 000 сообщений
DeepSeek V3.2	39 ₹	157 ₹	784 ₹
Qwen 3 235B (self-hosted)	56 ₹	224 ₹	1 120 ₹
Gemini 2.5 Flash	157 ₹	627 ₹	3 136 ₹
Claude Haiku 4.5	336 ₹	1 344 ₹	6 720 ₹
GigaChat 2 Pro	560 ₹	2 240 ₹	11 200 ₹
GPT-4.1	560 ₹	2 240 ₹	11 200 ₹
Claude Sonnet 4.6	1 008 ₹	4 032 ₹	20 160 ₹
YandexGPT 5 Pro	1 344 ₹	5 376 ₹	26 880 ₹

Міх-сценарии (типичные пользовательские профили)

Профиль	Состав	Cost/msg	Retail/msg	50 msg	200 msg	1 000 msg
A. MVP-эконом	70% DeepSeek + 20% Haiku + 10% Sonnet	1.40 ₹	3.91 ₹	195 ₹	782 ₹	3 909 ₹
B. Балансный	40% DS + 30% Haiku + 20% Gemini Flash + 10% Sonnet	1.78 ₹	4.97 ₹	249 ₹	995 ₹	4 973 ₹
C. Премиум	50% Sonnet + 30% Haiku + 20% GPT-4.1	5.12 ₹	14.34 ₹	717 ₹	2 867 ₹	14 336 ₹
D. 152-ФЗ enterprise	60% YandexGPT + 30% GigaChat + 10% Sonnet	7.68 ₹	21.50 ₹	1 075 ₹	4 301 ₹	21 504 ₹

5. Сколько сообщений покрывает кошелёк каждого тарифа

По модели (если юзер использует только её) и по балансному mix-профилю.

Тариф	Кошелёк ₹	DeepSeek V2.2	Qwen 3 235B (self-hosted)	Starcoder 2.5 Flash	Claude Haiku 4.5	GigaChat 2 Pro	GPT-4.1	Claude Sonnet 4.5	LlamaIndex GPT 5 Pro
Free (5 дней)	500 ₹	637	446	159	74	44	44	24	18
Lite	1 000 ₹	1 275	892	318	148	89	89	49	37
Starter	2 500 ₹	3 188	2 232	797	372	223	223	124	93
Pro	6 000 ₹	7 653	5 357	1 913	892	535	535	297	223
Enterprise	18 000 ₹	22 959	16 071	5 739	2 678	1 607	1 607	892	669

Балансный mix (4.98 ₹/msg)

Тариф	Кошелёк	Сообщений на балансном миксе
Free (5 дней)	500 ₹	100
Lite	1 000 ₹	201
Starter	2 500 ₹	502
Pro	6 000 ₹	1 206
Enterprise	18 000 ₹	3 619

6. Типичная нагрузка на 1 проект

Бенчмарк по типам проектов и стадиям жизненного цикла.

Тип проекта	Стадия	Msg/мес (диапазон)	Среднее	Тариф
Лендинг (1 страница)	Сборка с нуля	30–60	45	Lite
Лендинг	Активные правки (1-2 нед)	20–40	30	Lite
Лендинг	Поддержка / месяц	5–15	10	Lite
Магазин e-commerce	Сборка с нуля	80–150	120	Starter
Магазин	Сезон / распродажа	60–120	90	Starter
Корп-сайт SMB	Сборка с нуля	60–120	90	Starter
Портфолио / визитка	Сборка с нуля	20–50	35	Lite
SaaS-MVP с backend	Сборка с нуля	200–400	300	Pro
SaaS-MVP	Поддержка после релиза	30–80	55	Starter
Чат-бот TG/VK	Сборка с нуля	50–100	75	Starter
Бизнес-автоматизация	Сборка пайплайна	150–300	225	Pro
Агентство · 5 клиентов параллельно	Активная разработка	500–1000	750	Enterprise

- 80% обычных SMB-проектов укладываются в Lite (200 msg/мес на балансном миксе).
- Pro оправдан только при 200+ msg/мес — активный SaaS-MVP, чат-боты, или 2-3 проекта одновременно.
- Enterprise — для агентств с 5+ клиентами или больших проектов 1 000+ msg.
- Реальный паттерн: первый месяц активной сборки на Pro → downgrade на поддержку Lite. Учитываем в churn.

7. Lean cost-структура: только реальные затраты

Юрист + LLM (variable) + Серверум + домены/SSL + 300к/мес разработка. Никакого FOT-ramp и маркетингового бюджета.

Постоянные затраты (₽/мес, не зависят от числа клиентов)

Категория	₽/мес	Комментарий
Юрист	30 000 ₽	Договоры, оферта, ИП/ЮЛ обслуживание
Разработка	300 000 ₽	1 senior dev или 2 mid (founder + 1 hire)
ИТОГО ПОСТОЯННЫХ	330 000 ₽	

Серверум и домены клиента — НЕ в постоянных затратах. Когда мы продаём подписку на тариф, мы внутри её цены уже закладываем стоимость VPS от Серверум для сайта клиента и стоимость его домена + HTTPS. Это переменные затраты — они растут пропорционально числу клиентов и сразу окупаются их платежом. В fixed остаются только юрист и разработка.

Переменные затраты на клиента (профиль В — балансный)

Тариф	Цена	LLM (wallet/2.8)	Сервер	Домен	Комиссия 3%	Итого Var	GM ₽	GM %
Lite	990 ₽	357 ₽	50 ₽	25 ₽	30 ₽	462 ₽	528 ₽	53.3%
Starter	2 990 ₽	893 ₽	600 ₽	50 ₽	90 ₽	1 633 ₽	1 357 ₽	45.4%
Pro	7 990 ₽	2 143 ₽	3 000 ₽	100 ₽	240 ₽	5 483 ₽	2 507 ₽	31.4%
Enterprise	19 990 ₽	6 429 ₽	8 000 ₽	250 ₽	600 ₽	15 278 ₽	4 712 ₽	23.6%

8. Точка безубыточности

Зависит от микса тарифов. Чем больше Pro/Ent в миксе, тем меньше клиентов нужно для break-even.

Базовый расчёт (зрелый mix)

Параметр	Значение
ARPU средневзв.	4 080 Р
GM на 1 клиента/мес	1 385 Р
GM ratio (от MRR)	33.9%
Постоянный орех	330 000 Р
BREAK-EVEN: платящих клиентов	239
BREAK-EVEN: MRR Р/мес	975 120 Р

Чувствительность по миксу

Сценарий	Lite %	Starter %	Pro %	Ent %	ARPU Р	GM/cust Р	Break-even
Зрелый (M15+, default)	50%	25%	18%	7%	4 080 Р	1 385 Р	239
Lite-доминантный (M5-9)	80%	15%	4%	1%	1 760 Р	774 Р	427
Бизнес-mix (M10-14)	60%	25%	12%	3%	2 900 Р	1 098 Р	301
Премиум-tilt (M18+)	30%	25%	30%	15%	6 440 Р	1 957 Р	169
Только Pro/Ent (B2B fokus)	0%	0%	70%	30%	11 590 Р	3 169 Р	105

9. Финмодель 18 месяцев

Lean орех 330к/мес (только юрист + разработка). Сервера и домены клиентов — внутри подписки.

М	Платящих	ARPU	MRR	GM%	GM Р	EBITDA	Накоп. кэш
M1	0	990 Р	0 Р	53%	0 Р	-330 000 Р	-300 000 Р
M2	0	990 Р	0 Р	53%	0 Р	-330 000 Р	-630 000 Р
M3	0	990 Р	0 Р	53%	0 Р	-330 000 Р	-960 000 Р
M4	5	990 Р	4 950 Р	53%	2 624 Р	-327 376 Р	-1 287 376 Р
M5	15	1 100 Р	16 500 Р	52%	8 580 Р	-321 420 Р	-1 608 796 Р
M6	35	1 200 Р	42 000 Р	50%	21 000 Р	-309 000 Р	-1 917 796 Р
M7	60	1 400 Р	84 000 Р	48%	40 320 Р	-289 680 Р	-2 207 476 Р
M8	120	1 700 Р	204 000 Р	46%	93 840 Р	-236 160 Р	-2 443 636 Р
M9	200	2 000 Р	400 000 Р	44%	176 000 Р	-154 000 Р	-2 597 636 Р
M10	320	2 300 Р	736 000 Р	42%	309 120 Р	-20 880 Р	-2 618 516 Р
M11	480	2 600 Р	1 248 000 Р	40%	499 200 Р	169 200 Р	-2 449 316 Р
M12	680	2 900 Р	1 972 000 Р	38%	749 360 Р	419 360 Р	-2 029 956 Р
M13	920	3 150 Р	2 898 000 Р	37%	1 072 260 Р	742 260 Р	-1 287 696 Р
M14	1 180	3 400 Р	4 012 000 Р	36%	1 444 320 Р	1 114 320 Р	-173 376 Р
M15	1 450	3 650 Р	5 292 500 Р	35%	1 852 375 Р	1 522 375 Р	1 348 998 Р
M16	1 750	3 850 Р	6 737 500 Р	34%	2 290 750 Р	1 960 750 Р	3 309 748 Р
M17	2 050	3 950 Р	8 097 500 Р	34%	2 753 150 Р	2 423 150 Р	5 732 898 Р
M18	2 350	4 080 Р	9 588 000 Р	34%	3 259 920 Р	2 929 920 Р	8 662 818 Р

Метрика	Значение
MRR на M18	9 588 000 Р
ARR на M18	115 056 000 Р
Накопленный кэш на M18	8 662 818 Р
Min cash (наибольший провал)	-2 618 516 Р

Первый положительный EBITDA	M11
Накопленный кэш > 0	M15

10. Кеширование промптов

Anthropic / OpenAI: cached input reads = 10% of raw input. При 70% hit rate input стоимость падает на 63%.

Модель	Cost/msg без кеша	Cost/msg с кешем	Экономия %
DeepSeek V3.2	0.28 ₹	0.21 ₹	25.2%
Qwen 3 235B (self-hosted)	0.40 ₹	0.27 ₹	31.5%
Gemini 2.5 Flash	1.12 ₹	1.04 ₹	6.7%
Claude Haiku 4.5	2.40 ₹	2.15 ₹	10.5%
GigaChat 2 Pro	4.00 ₹	2.74 ₹	31.5%
GPT-4.1	4.00 ₹	3.50 ₹	12.6%
Claude Sonnet 4.6	7.20 ₹	6.44 ₹	10.5%
YandexGPT 5 Pro	9.60 ₹	7.58 ₹	21.0%

Эффективный множитель input при cache_hit=70%, cache_price=10%: 37.0% (экономия 63% на input).
Power-user Pro (1 200 msg на балансом миксе) получает примерно +6.5% gross margin от одного только кеша.

11. Self-hosted Qwen 3 235B — break-even

Серех 250к ₺ + Орех 120к/мес. Окупается с 500+ активных Pro юзеров.

Параметр	Значение
Серех (1× A100 80GB или 2× RTX 4090)	250 000 ₺
Орех/мес (электр., охлаждение, амортизация 5у)	120 000 ₺
Throughput на 1 GPU	60 msg/час (8K токенов, batch=4)
Uptime	720 ч/мес
Capacity Qwen	43 200 msg/мес
Cost ₺/msg на Qwen	2.78 ₺
Доля задач, роутируемых на Qwen	30%

Break-even по объёму активной базы (vs Sonnet API)

Активных Pro	Msg/мес total	Msg на Qwen	Sonnet API ₺	Qwen Орех ₺	Экономия /мес	Месяцев до break-even
50	10 000 ₺	3 000	21 600 ₺	120 000 ₺	-98 400 ₺	никогда
100	20 000 ₺	6 000	43 200 ₺	120 000 ₺	-76 800 ₺	никогда
200	40 000 ₺	12 000	86 400 ₺	120 000 ₺	-33 600 ₺	никогда
500	100 000 ₺	30 000	216 000 ₺	120 000 ₺	96 000 ₺	2.6
1 000	200 000 ₺	43 200	311 040 ₺	120 000 ₺	191 040 ₺	1.3
2 000	400 000 ₺	43 200	311 040 ₺	120 000 ₺	191 040 ₺	1.3
5 000	1 000 000 ₺	43 200	311 040 ₺	120 000 ₺	191 040 ₺	1.3

До 200 юзеров: Qwen НЕ окупается — орех 120к/мес больше экономии на API.
200–500 юзеров: 4–12 мес до break-even. Только если есть стратегические причины (152-ФЗ, lock-in).
500+ юзеров: 1–3 мес до break-even — однозначно ставить.
По плану M15: ~1 000 платящих → break-even на 4-м месяце с launch'a Qwen.
Стратегия: 152-ФЗ из коробки + защита от блокировки API + R&D-;площадка для fine-tune под Tilda/ЮKassa/1C.

12. Главные цифры за один взгляд

Если у вас 30 секунд на этот документ — вот ключевые числа.

1. Себестоимость одного сообщения: 0.28 → 9.60 ₽ в зависимости от AI-модели.
2. 200 сообщений в реальном миксе моделей стоят юзеру ≈ 1 000 ₽ = ровно Lite-кошелёк.
3. На каждом платящем клиенте мы зарабатываем в среднем 1 385 ₽/мес.
4. Постоянные траты компании — 330 К ₽/мес (юрист 30 + разработка 300). Сервера и домены клиентов — внутри подписки.
5. Точка плюса — 239 платящих клиентов (≈ месяц 11).
6. За 18 месяцев модель выходит на 9.6 М ₽/мес выручки и +7.7 М ₽ на счёте.
7. Запускаться можно без инвесторов, нужно ~2.65 М ₽ оборотки на первые 10 месяцев.
8. Сравнение с v2 plan (с маркет.+FOT 3.5M): break-even с 858 → 239 (−72%); Min cash с 28M → 2.65M (−91%).

Источник: Token_Economics_v1.xlsx (15 листов с живыми формулами). Всё, что в PDF — это снапшот калькулятора. Меняй параметры в XLSX чтобы пересчитать.