

Omnia.AI

Подробная токен-экономика

Расчёт LLM-затрат, кошельков и маржи по тарифам
Free / Lite / Starter / Pro / Enterprise

30 К/мес

постоянные плати

M5

первоа прибыль

M7

вернул вложенное

27 М Р

на счёт M18

1. Базовые допущения

Все расчёты в документе строятся на этих 4 параметрах. На листе «1. Параметры» XLSX-калькулятора их можно менять.

Параметр	Значение	Комментарий
Размер сообщения	8 000 токенов	5 000 input + 3 000 output. Conservative-среднее для AI-code-gen.
Output share	0.5	Половина от 1M общих токенов — output. Стандарт для chat-LLM.
Markup на токены	2.8×	Себестоимость + ~64% валовая маржа на токенах.
Курс ₽/\$	100	На 2025.

2. LLM-стек: 8 моделей

Себестоимость 1 миллиона токенов = (цена input × 0.5 + цена output × 0.5) × 100 ₽/\$. Цена клиенту = себестоимость × 2.8.

AI-модель	Категория	Цена input \$/1M	Цена output \$/1M	Себест ₽/1M	Цена клиенту ₽/1M
DeepSeek V3.2	ультра-эконом	0.28	0.42	35 ₽	98 ₽
Qwen 3 235B (self-hosted)	ультра-эконом	0.50	0.50	50 ₽	140 ₽
Gemini 2.5 Flash	эконом	0.30	2.50	140 ₽	392 ₽
Claude Haiku 4.5	баланс	1.00	5.00	300 ₽	840 ₽
GigaChat 2 Pro	152-ФЗ	5.00	5.00	500 ₽	1 400 ₽
GPT-4.1	премиум	2.00	8.00	500 ₽	1 400 ₽
Claude Sonnet 4.6	премиум	3.00	15.00	900 ₽	2 520 ₽
YandexGPT 5 Pro	152-ФЗ премиум	8.00	16.00	1 200 ₽	3 360 ₽

3. Стоимость 1 сообщения (8 000 токенов)

Себестоимость 1 сообщения = себестоимость 1 миллиона × 0.008 (8K токенов). Цена клиенту = себестоимость × 2.8.

AI-модель	Себест ₹ за сообщение	Цена клиенту	Маржа ₹	Маржа %
DeepSeek V3.2	0.28 ₹	0.78 ₹	0.50 ₹	64.3%
Qwen 3 235B (self-hosted)	0.40 ₹	1.12 ₹	0.72 ₹	64.3%
Gemini 2.5 Flash	1.12 ₹	3.14 ₹	2.02 ₹	64.3%
Claude Haiku 4.5	2.40 ₹	6.72 ₹	4.32 ₹	64.3%
GigaChat 2 Pro	4.00 ₹	11.20 ₹	7.20 ₹	64.3%
GPT-4.1	4.00 ₹	11.20 ₹	7.20 ₹	64.3%
Claude Sonnet 4.6	7.20 ₹	20.16 ₹	12.96 ₹	64.3%
YandexGPT 5 Pro	9.60 ₹	26.88 ₹	17.28 ₹	64.3%

4. Сколько стоит 50 / 200 / 1 000 сообщений

Цена что заплатит пользователь. 50 сообщений = 400 К токенов · 200 = 1.6 М · 1 000 = 8 М.

Модель	50 сообщений	200 сообщений	1 000 сообщений
DeepSeek V3.2	39 ₹	157 ₹	784 ₹
Qwen 3 235B (self-hosted)	56 ₹	224 ₹	1 120 ₹
Gemini 2.5 Flash	157 ₹	627 ₹	3 136 ₹
Claude Haiku 4.5	336 ₹	1 344 ₹	6 720 ₹
GigaChat 2 Pro	560 ₹	2 240 ₹	11 200 ₹
GPT-4.1	560 ₹	2 240 ₹	11 200 ₹
Claude Sonnet 4.6	1 008 ₹	4 032 ₹	20 160 ₹
YandexGPT 5 Pro	1 344 ₹	5 376 ₹	26 880 ₹

Міх-сценарии (типичные пользовательские профили)

Профиль	Состав	Себест/сообщ	Цена клиенту	50 сообщ	200 сообщ	1 000 сообщ
A. MVP-эконом	70% DeepSeek + 20% Haiku + 10% Sonnet	1.40 ₹	3.91 ₹	195 ₹	782 ₹	3 909 ₹
B. Балансный	40% DS + 30% Haiku + 20% Gemini Flash + 10% Sonnet	1.78 ₹	4.97 ₹	249 ₹	995 ₹	4 973 ₹
C. Премиум	50% Sonnet + 30% Haiku + 20% GPT-4.1	5.12 ₹	14.34 ₹	717 ₹	2 867 ₹	14 336 ₹
D. 152-ФЗ enterprise	60% YandexGPT + 30% GigaChat + 10% Sonnet	7.68 ₹	21.50 ₹	1 075 ₹	4 301 ₹	21 504 ₹

5. Сколько сообщений покрывает кошелёк каждого тарифа

По модели (если юзер использует только её) и по балансному mix-профилю.

Тариф	Кошелёк ₹	DeepSeek V2.2	Qwen 3 235B (self-hosted)	Starcoder 2.5 Flash	Claude Haiku 4.5	GigaChat 2 Pro	GPT-4.1	Claude Sonnet 4.5	LlamaIndex GPT 5 Pro
Free (5 дней)	500 ₹	637	446	159	74	44	44	24	18
Lite	1 000 ₹	1 275	892	318	148	89	89	49	37
Starter	2 500 ₹	3 188	2 232	797	372	223	223	124	93
Pro	6 000 ₹	7 653	5 357	1 913	892	535	535	297	223
Enterprise	18 000 ₹	22 959	16 071	5 739	2 678	1 607	1 607	892	669

Балансный mix (4.98 ₹/msg)

Тариф	Кошелёк	Сообщений на балансном миксе
Free (5 дней)	500 ₹	100
Lite	1 000 ₹	201
Starter	2 500 ₹	502
Pro	6 000 ₹	1 206
Enterprise	18 000 ₹	3 619

6. Типичная нагрузка на 1 проект

Бенчмарк по типам проектов и стадиям жизненного цикла.

Тип проекта	Стадия	Msg/мес (диапазон)	Среднее	Тариф
Лендинг (1 страница)	Сборка с нуля	30–60	45	Lite
Лендинг	Активные правки (1-2 нед)	20–40	30	Lite
Лендинг	Поддержка / месяц	5–15	10	Lite
Магазин e-commerce	Сборка с нуля	80–150	120	Starter
Магазин	Сезон / распродажа	60–120	90	Starter
Корп-сайт SMB	Сборка с нуля	60–120	90	Starter
Портфолио / визитка	Сборка с нуля	20–50	35	Lite
SaaS-MVP с backend	Сборка с нуля	200–400	300	Pro
SaaS-MVP	Поддержка после релиза	30–80	55	Starter
Чат-бот TG/VK	Сборка с нуля	50–100	75	Starter
Бизнес-автоматизация	Сборка пайплайна	150–300	225	Pro
Агентство · 5 клиентов параллельно	Активная разработка	500–1000	750	Enterprise

- 80% обычных SMB-проектов укладываются в Lite (200 сообщ/мес на балансном миксе).
- Pro оправдан только при 200+ сообщ/мес — активный SaaS-MVP, чат-боты, или 2-3 проекта одновременно.
- Enterprise — для агентств с 5+ клиентами или больших проектов 1 000+ msg.
- Реальный паттерн: первый месяц активной сборки на Pro → downgrade на поддержку Lite. Учитываем в churn.

7. Lean cost-структура: только реальные затраты

Юрист + LLM (variable) + Серверум + домены/SSL + 300к/мес разработка. Никакого FOT-ramp и маркетингового бюджета.

Постоянные затраты (₽/мес, не зависят от числа клиентов)

Категория	₽/мес	Комментарий
Юрист	30 000 ₽	Договоры, оферта, ИП/ЮЛ обслуживание
ИТОГО ПОСТОЯННЫХ	30 000 ₽	

Серверум и домены клиента — НЕ в постоянных затратах. Когда мы продаём подписку на тариф, мы внутри её цены уже закладываем стоимость VPS от Серверум для сайта клиента и стоимость его домена + HTTPS. Это переменные затраты — они растут пропорционально числу клиентов и сразу окупаются их платежом. В fixed остаются только юрист и разработка.

Переменные затраты на клиента (профиль В — балансный)

Тариф	Цена	Затраты на AI (кошелёк ÷ 2.8)	Сервер	Домен	Комиссия 3%	Все затраты	Маржа ₽	Маржа %
Lite	990 ₽	357 ₽	50 ₽	25 ₽	30 ₽	462 ₽	528 ₽	53.3%
Starter	2 990 ₽	893 ₽	600 ₽	50 ₽	90 ₽	1 633 ₽	1 357 ₽	45.4%
Pro	7 990 ₽	2 143 ₽	3 000 ₽	100 ₽	240 ₽	5 483 ₽	2 507 ₽	31.4%
Enterprise	19 990 ₽	6 429 ₽	8 000 ₽	250 ₽	600 ₽	15 278 ₽	4 712 ₽	23.6%

8. Точка безубыточности

Зависит от того, какие тарифы покупают чаще. Чем больше Pro/Enterprise — тем меньше клиентов нужно чтобы выйти в плюс.

Базовый расчёт (зрелый mix)

Параметр	Значение
Средний доход с клиента в месяц	4 080 Р
Маржа на 1 клиента/мес	1 385 Р
Маржа в % от выручки	33.9%
Постоянный орех	30 000 Р
Точка безубыточности: платящих клиентов	22
Точка безубыточности: выручка Р/мес	89 760 Р

Чувствительность по миксу

Сценарий	Lite %	Starter %	Pro %	Ent %	Доход с клиента	Маржа на клиента	Клиентов до плюс
Зрелый (M15+, default)	50%	25%	18%	7%	4 080 Р	1 385 Р	22
Lite-доминантный (M5-9)	80%	15%	4%	1%	1 760 Р	774 Р	39
Бизнес-mix (M10-14)	60%	25%	12%	3%	2 900 Р	1 098 Р	28
Премиум-tilt (M18+)	30%	25%	30%	15%	6 440 Р	1 957 Р	16
Только Pro/Ent (B2B fokus)	0%	0%	70%	30%	11 590 Р	3 169 Р	10

9. Финмодель 18 месяцев

Founders разрабатывают сами (без зарплат). Месяц 1 — soft-launch, юрист 30к. Месяц 2 — реклама. Минимум денег нужно ~250к Р на первые 6 месяцев — самый bootstrap-friendly сценарий.

Месяц	Платящих	Доход с клиента	Выручка/мес	Маржа %	Маржа Р	Маркетинг	Прибыль/убыток	Деньги на счёте
M1	0	0 Р	0 Р	0%	0 Р	0 Р	-30 000 Р	0 Р
M2	30	990 Р	29 700 Р	53%	15 741 Р	100 000 Р	-114 259 Р	-114 259 Р
M3	80	990 Р	79 200 Р	53%	41 976 Р	100 000 Р	-88 024 Р	-202 283 Р
M4	150	1 100 Р	165 000 Р	52%	85 800 Р	100 000 Р	-44 200 Р	-246 483 Р
M5	250	1 200 Р	300 000 Р	50%	150 000 Р	100 000 Р	20 000 Р	-226 483 Р
M6	380	1 400 Р	532 000 Р	48%	255 360 Р	150 000 Р	75 360 Р	-151 123 Р
M7	540	1 700 Р	918 000 Р	46%	422 280 Р	150 000 Р	242 280 Р	91 157 Р
M8	720	2 000 Р	1 440 000 Р	44%	633 600 Р	150 000 Р	453 600 Р	544 757 Р
M9	920	2 300 Р	2 116 000 Р	42%	888 720 Р	150 000 Р	708 720 Р	1 253 477 Р
M10	1 140	2 600 Р	2 964 000 Р	40%	1 185 600 Р	200 000 Р	955 600 Р	2 209 077 Р
M11	1 390	2 900 Р	4 031 000 Р	38%	1 531 780 Р	200 000 Р	1 301 780 Р	3 510 857 Р
M12	1 670	3 150 Р	5 260 500 Р	37%	1 946 385 Р	200 000 Р	1 716 385 Р	5 227 242 Р
M13	1 980	3 400 Р	6 732 000 Р	36%	2 423 520 Р	200 000 Р	2 193 520 Р	7 420 762 Р
M14	2 330	3 650 Р	8 504 500 Р	35%	2 976 575 Р	200 000 Р	2 746 575 Р	10 167 337 Р
M15	2 710	3 850 Р	10 433 500 Р	34%	3 547 390 Р	250 000 Р	3 267 390 Р	13 434 727 Р
M16	3 120	3 950 Р	12 324 000 Р	34%	4 190 160 Р	250 000 Р	3 910 160 Р	17 344 887 Р
M17	3 550	4 030 Р	14 306 500 Р	34%	4 864 210 Р	250 000 Р	4 584 210 Р	21 929 097 Р
M18	4 000	4 080 Р	16 320 000 Р	34%	5 548 800 Р	250 000 Р	5 268 800 Р	27 197 897 Р

Метрика	Значение
Выручка в мес на M18	16 320 000 Р
Выручка в год на M18	195 840 000 Р
Накопленный кэш на M18	27 197 897 Р

Самый большой минус по деньгам	-246 483 Р
Первый плюсовой месяц (прибыль > расходов)	M5
Когда вернули вложенные деньги	M7
Маркетинг суммарно за 18 мес	3 000 000 Р

10. Кеширование промптов

Anthropic / OpenAI: cached input reads = 10% of raw input. При 70% hit rate input стоимость падает на 63%.

AI-модель	Себест/сообщ без кеша	Себест/сообщ с кешем	Экономия %
DeepSeek V3.2	0.28 ₺	0.21 ₺	25.2%
Qwen 3 235B (self-hosted)	0.40 ₺	0.27 ₺	31.5%
Gemini 2.5 Flash	1.12 ₺	1.04 ₺	6.7%
Claude Haiku 4.5	2.40 ₺	2.15 ₺	10.5%
GigaChat 2 Pro	4.00 ₺	2.74 ₺	31.5%
GPT-4.1	4.00 ₺	3.50 ₺	12.6%
Claude Sonnet 4.6	7.20 ₺	6.44 ₺	10.5%
YandexGPT 5 Pro	9.60 ₺	7.58 ₺	21.0%

Эффективный множитель input при cache_hit=70%, cache_price=10%: 37.0% (экономия 63% на input).
Power-user Pro (1 200 msg на балансом миксе) получает примерно +6.5% gross margin от одного только кеша.

11. Свой AI-сервер Qwen 3 235B — когда окупится

Покупка железа 250к Р + текущие траты 120к/мес. Окупается с 500+ активных Pro клиентов.

Параметр	Значение
Покупка железа (1× A100 80GB или 2× RTX 4090)	250 000 Р
Текущие траты в месяц (электричество + охлаждение + износ за 5 лет)	120 000 Р
Производительность на 1 видеокарту	60 сообщений/час (8K токенов)
Часов работы в месяц	720 ч/мес
Сколько сообщений может обработать в месяц	43 200 сообщений
Себестоимость 1 сообщения на Qwen	2.78 Р
Доля задач, отправляемых на Qwen	30%

Когда окупится: зависит от количества активных Pro-клиентов (сравнение со стоимостью Sonnet через API)

Активных Pro	Сообщений/мес всего	Сообщений на Qwen	Если бы Sonnet, Р	Текущие на Qwen, Р	Экономия в мес	Месяцев до окупаемости
50	10 000 Р	3 000	21 600 Р	120 000 Р	-98 400 Р	никогда
100	20 000 Р	6 000	43 200 Р	120 000 Р	-76 800 Р	никогда
200	40 000 Р	12 000	86 400 Р	120 000 Р	-33 600 Р	никогда
500	100 000 Р	30 000	216 000 Р	120 000 Р	96 000 Р	2.6
1 000	200 000 Р	43 200	311 040 Р	120 000 Р	191 040 Р	1.3
2 000	400 000 Р	43 200	311 040 Р	120 000 Р	191 040 Р	1.3
5 000	1 000 000 Р	43 200	311 040 Р	120 000 Р	191 040 Р	1.3

До 200 клиентов: Qwen НЕ окупается — текущие траты 120к/мес больше экономии на API.
200–500 клиентов: 4–12 мес до окупаемости. Только если есть стратегические причины (закон 152-ФЗ, защита от блокировки).
500+ клиентов: 1–3 мес до окупаемости — однозначно стоит ставить.
По плану на M15: ~1 000 платящих → окупится на 4-м месяце после запуска Qwen.
Зачем вообще: закон 152-ФЗ из коробки + защита от блокировки западных AI + площадка для дообучения под Tilda/ЮKassa/1C.

12. Главные цифры за один взгляд

Если у вас 30 секунд на этот документ — вот ключевые числа.

1. Себестоимость одного сообщения: 0.28 → 9.60 ₽ в зависимости от AI-модели.
2. 200 сообщений в реальном миксе моделей стоят юзеру ≈ 1 000 ₽ = ровно Lite-кошелёк.
3. На каждом платящем клиенте мы зарабатываем в среднем 1 385 ₽/мес.
4. Базовые расходы компании — 30 К ₽/мес (только юрист). Founders разрабатывают сами без зарплат — это и есть главная выгода.
5. С месяца 2 включается маркетинг 100 → 250 К/мес. Прибыль покроет расходы уже на месяце 5 при 250 платящих.
6. За 18 месяцев модель выходит на 16.3 М ₽/мес выручки (~196 М в год) и +27 М ₽ на счёте.
7. Самый большой минус — всего ~250 К ₽ на месяце 4. Это в 8 раз меньше чем при найме разработчиков.
8. Запускаться можно без инвесторов и почти без денег: 30 К ₽ хватит на месяц 1, дальше выручка покрывает.

Источник: Token_Economics_v1.xlsx (15 листов с живыми формулами). Всё, что в PDF — это снапшот калькулятора. Меняй параметры в XLSX чтобы пересчитать.