

Omnia.AI

Подробная токен-экономика

Расчёт LLM-затрат, кошельков и маржи по тарифам
Free / Lite / Starter / Pro / Enterprise

30 К/мес

сервис построения

M6

первая прибыль

M8

вернули вложенное

67 М Р

на счете M24

1. Базовые допущения

Все расчёты в документе строятся на этих 4 параметрах. На листе «1. Параметры» XLSX-калькулятора их можно менять.

Параметр	Значение	Комментарий
Размер сообщения	8 000 токенов	5 000 input + 3 000 output. Conservative-среднее для AI-code-gen.
Output share	0.5	Половина от 1M общих токенов — output. Стандарт для chat-LLM.
Markup на токены	2.8×	Себестоимость + ~64% валовая маржа на токенах.
Курс ₽/\$	100	На 2025.

2. LLM-стек: 8 моделей

Себестоимость 1 миллиона токенов = (цена input × 0.5 + цена output × 0.5) × 100 ₽/\$. Цена клиенту = себестоимость × 2.8.

AI-модель	Категория	Цена input \$/1M	Цена output \$/1M	Себест ₽/1M	Цена клиенту ₽/1M
DeepSeek V3.2	ультра-эконом	0.28	0.42	35 ₽	98 ₽
Qwen 3 235B (self-hosted)	ультра-эконом	0.50	0.50	50 ₽	140 ₽
Gemini 2.5 Flash	эконом	0.30	2.50	140 ₽	392 ₽
Claude Haiku 4.5	баланс	1.00	5.00	300 ₽	840 ₽
GigaChat 2 Pro	152-ФЗ	5.00	5.00	500 ₽	1 400 ₽
GPT-4.1	премиум	2.00	8.00	500 ₽	1 400 ₽
Claude Sonnet 4.6	премиум	3.00	15.00	900 ₽	2 520 ₽
YandexGPT 5 Pro	152-ФЗ премиум	8.00	16.00	1 200 ₽	3 360 ₽

3. Стоимость 1 сообщения (8 000 токенов)

Себестоимость 1 сообщения = себестоимость 1 миллиона × 0.008 (8K токенов). Цена клиенту = себестоимость × 2.8.

AI-модель	Себест ₽ за сообщение	Цена клиенту	Маржа ₽	Маржа %
DeepSeek V3.2	0.28 ₽	0.78 ₽	0.50 ₽	64.3%
Qwen 3 235B (self-hosted)	0.40 ₽	1.12 ₽	0.72 ₽	64.3%
Gemini 2.5 Flash	1.12 ₽	3.14 ₽	2.02 ₽	64.3%
Claude Haiku 4.5	2.40 ₽	6.72 ₽	4.32 ₽	64.3%
GigaChat 2 Pro	4.00 ₽	11.20 ₽	7.20 ₽	64.3%
GPT-4.1	4.00 ₽	11.20 ₽	7.20 ₽	64.3%
Claude Sonnet 4.6	7.20 ₽	20.16 ₽	12.96 ₽	64.3%
YandexGPT 5 Pro	9.60 ₽	26.88 ₽	17.28 ₽	64.3%

4. Сколько стоит 50 / 200 / 1 000 сообщений

Цена что заплатит пользователь. 50 сообщений = 400 К токенов · 200 = 1.6 М · 1 000 = 8 М.

Модель	50 сообщений	200 сообщений	1 000 сообщений
DeepSeek V3.2	39 ₺	157 ₺	784 ₺
Qwen 3 235B (self-hosted)	56 ₺	224 ₺	1 120 ₺
Gemini 2.5 Flash	157 ₺	627 ₺	3 136 ₺
Claude Haiku 4.5	336 ₺	1 344 ₺	6 720 ₺
GigaChat 2 Pro	560 ₺	2 240 ₺	11 200 ₺
GPT-4.1	560 ₺	2 240 ₺	11 200 ₺
Claude Sonnet 4.6	1 008 ₺	4 032 ₺	20 160 ₺
YandexGPT 5 Pro	1 344 ₺	5 376 ₺	26 880 ₺

Міх-сценарии (типичные пользовательские профили)

Профиль	Состав	Себест/сообщ	Цена клиенту	50 сообщ	200 сообщ	1 000 сообщ
A. MVP-эконом	70% DeepSeek + 20% Haiku + 10% Sonnet	1.40 ₺	3.91 ₺	195 ₺	782 ₺	3 909 ₺
B. Балансный	40% DS + 30% Haiku + 20% Gemini Flash + 10% Sonnet	1.78 ₺	4.97 ₺	249 ₺	995 ₺	4 973 ₺
C. Премиум	50% Sonnet + 30% Haiku + 20% GPT-4.1	5.12 ₺	14.34 ₺	717 ₺	2 867 ₺	14 336 ₺
D. 152-ФЗ enterprise	60% YandexGPT + 30% GigaChat + 10% Sonnet	7.68 ₺	21.50 ₺	1 075 ₺	4 301 ₺	21 504 ₺

5. Сколько сообщений покрывает кошелёк каждого тарифа

По модели (если юзер использует только её) и по балансному mix-профилю.

Тариф	Кошелёк ₹	DeepSeek V2.2	Qwen 3 235B (self-hosted)	Starcoder 2.5 Flash	Claude Haiku 4.5	GigaChat 2 Pro	GPT-4.1	Claude Sonnet 4.5	LlamaIndex GPT 5 Pro
Free (5 дней)	500 ₹	637	446	159	74	44	44	24	18
Lite	1 000 ₹	1 275	892	318	148	89	89	49	37
Starter	2 500 ₹	3 188	2 232	797	372	223	223	124	93
Pro	6 000 ₹	7 653	5 357	1 913	892	535	535	297	223
Enterprise	18 000 ₹	22 959	16 071	5 739	2 678	1 607	1 607	892	669

Балансный mix (4.98 ₹/msg)

Тариф	Кошелёк	Сообщений на балансном миксе
Free (5 дней)	500 ₹	100
Lite	1 000 ₹	201
Starter	2 500 ₹	502
Pro	6 000 ₹	1 206
Enterprise	18 000 ₹	3 619

6. Типичная нагрузка на 1 проект

Бенчмарк по типам проектов и стадиям жизненного цикла.

Тип проекта	Стадия	Msg/мес (диапазон)	Среднее	Тариф
Лендинг (1 страница)	Сборка с нуля	30–60	45	Lite
Лендинг	Активные правки (1-2 нед)	20–40	30	Lite
Лендинг	Поддержка / месяц	5–15	10	Lite
Магазин e-commerce	Сборка с нуля	80–150	120	Starter
Магазин	Сезон / распродажа	60–120	90	Starter
Корп-сайт SMB	Сборка с нуля	60–120	90	Starter
Портфолио / визитка	Сборка с нуля	20–50	35	Lite
SaaS-MVP с backend	Сборка с нуля	200–400	300	Pro
SaaS-MVP	Поддержка после релиза	30–80	55	Starter
Чат-бот TG/VK	Сборка с нуля	50–100	75	Starter
Бизнес-автоматизация	Сборка пайплайна	150–300	225	Pro
Агентство · 5 клиентов параллельно	Активная разработка	500–1000	750	Enterprise

- 80% обычных SMB-проектов укладываются в Lite (200 сообщ/мес на балансном миксе).
- Pro оправдан только при 200+ сообщ/мес — активный SaaS-MVP, чат-боты, или 2-3 проекта одновременно.
- Enterprise — для агентств с 5+ клиентами или больших проектов 1 000+ msg.
- Реальный паттерн: первый месяц активной сборки на Pro → downgrade на поддержку Lite. Учитываем в churn.

7. Lean cost-структура: только реальные затраты

Юрист + LLM (variable) + Серверум клиенту + домены клиенту + НАША инфра (растёт). Никакого FOT-ramp.

Постоянные затраты (₽/мес, не зависят от числа клиентов)

Категория	₽/мес	Комментарий
Юрист	30 000 ₽	Договоры, оферта, ИП/ЮЛ обслуживание
ИТОГО ПОСТОЯННЫХ	30 000 ₽	

Полу-переменные затраты — наша инфраструктура (₽/мес, растут с базой)

Размер базы	Наша инфра ₽/мес	Что входит
0–50 платящих	8 000 ₽	1 staging VPS + minimum monitoring
50–250	10–25 К ₽	Primary PG + S3 backups
250–1 000	35–65 К ₽	Read-replica + Redis + Grafana stack
1 000–2 500	80–160 К ₽	Cluster + DR setup + observability tools
2 500–5 000	180–280 К ₽	Multi-region backups + CDN + DDoS
5 000–6 250	300–380 К ₽	Premium ops + on-call SRE infra

Серверум и домены КЛИЕНТА — отдельно, в variable COGS внутри тарифа. Когда клиент платит за тариф, мы уже заложили туда VPS Серверум для его сайта + его домен + HTTPS. Это переменные затраты — окупаются его платежом. Наша инфра (control plane: API, БД, Redis, S3-бэкапы, мониторинг, CDN, DDoS) — растёт с базой, но медленнее: при 6 250 клиентов это ~6% от ARPU.

Переменные затраты на клиента (профиль В — балансный)

Тариф	Цена	Затраты на AI (кошелёк ÷ 2.8)	Сервер	Домен	Комиссия 3%	Все затраты	Маржа ₽	Маржа %
Lite	990 ₽	357 ₽	50 ₽	25 ₽	30 ₽	462 ₽	528 ₽	53.3%
Starter	2 990 ₽	893 ₽	600 ₽	50 ₽	90 ₽	1 633 ₽	1 357 ₽	45.4%
Pro	7 990 ₽	2 143 ₽	3 000 ₽	100 ₽	240 ₽	5 483 ₽	2 507 ₽	31.4%
Enterprise	19 990 ₽	6 429 ₽	8 000 ₽	250 ₽	600 ₽	15 278 ₽	4 712 ₽	23.6%

8. Точка безубыточности

Зависит от того, какие тарифы покупают чаще. Чем больше Pro/Enterprise — тем меньше клиентов нужно чтобы выйти в плюс.

Базовый расчёт (зрелый mix)

Параметр	Значение
Средний доход с клиента в месяц	4 080 Р
Маржа на 1 клиента/мес	1 385 Р
Маржа в % от выручки	33.9%
Постоянный орех	30 000 Р
Точка безубыточности: платящих клиентов	22
Точка безубыточности: выручка Р/мес	89 760 Р

Чувствительность по миксу

Сценарий	Lite %	Starter %	Pro %	Ent %	Доход с клиента	Маржа на клиента	Клиентов до плюс
Зрелый (M15+, default)	50%	25%	18%	7%	4 080 Р	1 385 Р	22
Lite-доминантный (M5-9)	80%	15%	4%	1%	1 760 Р	774 Р	39
Бизнес-mix (M10-14)	60%	25%	12%	3%	2 900 Р	1 098 Р	28
Премиум-tilt (M18+)	30%	25%	30%	15%	6 440 Р	1 957 Р	16
Только Pro/Ent (B2B fokus)	0%	0%	70%	30%	11 590 Р	3 169 Р	10

9. Финмодель 24 месяца (с учётом инфры)

Founders разрабатывают сами без зарплат. M1 soft-launch · с M2 — реклама · наша инфра растёт от 8к до 380к/мес параллельно базе клиентов. Минимум ~305к ₽ на первые 5 мес.

Мес	Платящ	ARPU	Выручка	Маржа%	Маржа ₽	Маркет	Инфра	Приб/убыт	На счёте
M1	0	0 ₽	0 ₽	0%	0 ₽	0 ₽	8 000 ₽	-38 000 ₽	-8 000 ₽
M2	30	990 ₽	29 700 ₽	53%	15 741 ₽	100 000 ₽	10 000 ₽	-124 259 ₽	-132 259 ₽
M3	80	990 ₽	79 200 ₽	53%	41 976 ₽	100 000 ₽	15 000 ₽	-103 024 ₽	-235 283 ₽
M4	150	1 100 ₽	165 000 ₽	52%	85 800 ₽	100 000 ₽	20 000 ₽	-64 200 ₽	-299 483 ₽
M5	250	1 200 ₽	300 000 ₽	50%	150 000 ₽	100 000 ₽	25 000 ₽	-5 000 ₽	-304 483 ₽
M6	380	1 400 ₽	532 000 ₽	48%	255 360 ₽	150 000 ₽	35 000 ₽	40 360 ₽	-264 123 ₽
M7	540	1 700 ₽	918 000 ₽	46%	422 280 ₽	150 000 ₽	45 000 ₽	197 280 ₽	-66 843 ₽
M8	720	2 000 ₽	1 440 000 ₽	44%	633 600 ₽	150 000 ₽	55 000 ₽	398 600 ₽	331 757 ₽
M9	920	2 300 ₽	2 116 000 ₽	42%	888 720 ₽	150 000 ₽	65 000 ₽	643 720 ₽	975 477 ₽
M10	1 140	2 600 ₽	2 964 000 ₽	40%	1 185 600 ₽	200 000 ₽	80 000 ₽	875 600 ₽	1 851 077 ₽
M11	1 390	2 900 ₽	4 031 000 ₽	38%	1 531 780 ₽	200 000 ₽	100 000 ₽	1 201 780 ₽	3 052 857 ₽
M12	1 670	3 150 ₽	5 260 500 ₽	37%	1 946 385 ₽	200 000 ₽	120 000 ₽	1 596 385 ₽	4 649 242 ₽
M13	1 980	3 400 ₽	6 732 000 ₽	36%	2 423 520 ₽	200 000 ₽	140 000 ₽	2 053 520 ₽	6 702 762 ₽
M14	2 330	3 650 ₽	8 504 500 ₽	35%	2 976 575 ₽	200 000 ₽	160 000 ₽	2 586 575 ₽	9 289 337 ₽
M15	2 710	3 850 ₽	10 433 500 ₽	34%	3 547 390 ₽	250 000 ₽	180 000 ₽	3 087 390 ₽	12 376 727 ₽
M16	3 120	3 950 ₽	12 324 000 ₽	34%	4 190 160 ₽	250 000 ₽	200 000 ₽	3 710 160 ₽	16 086 887 ₽
M17	3 550	4 030 ₽	14 306 500 ₽	34%	4 864 210 ₽	250 000 ₽	230 000 ₽	4 354 210 ₽	20 441 097 ₽
M18	4 000	4 080 ₽	16 320 000 ₽	34%	5 548 800 ₽	250 000 ₽	260 000 ₽	5 008 800 ₽	25 449 897 ₽
M19	4 400	4 080 ₽	17 952 000 ₽	34%	6 103 680 ₽	250 000 ₽	280 000 ₽	5 543 680 ₽	30 993 577 ₽
M20	4 800	4 100 ₽	19 680 000 ₽	34%	6 691 200 ₽	250 000 ₽	300 000 ₽	6 111 200 ₽	37 104 777 ₽
M21	5 200	4 120 ₽	21 424 000 ₽	34%	7 284 160 ₽	300 000 ₽	320 000 ₽	6 634 160 ₽	43 738 937 ₽
M22	5 550	4 140 ₽	22 977 000 ₽	34%	7 812 180 ₽	300 000 ₽	340 000 ₽	7 142 180 ₽	50 881 117 ₽
M23	5 900	4 150 ₽	24 485 000 ₽	34%	8 324 900 ₽	300 000 ₽	360 000 ₽	7 634 900 ₽	58 516 017 ₽
M24	6 250	4 160 ₽	26 000 000 ₽	34%	8 840 000 ₽	300 000 ₽	380 000 ₽	8 130 000 ₽	66 646 017 ₽

Метрика	Значение
---------	----------

Выручка в мес на M24	26 000 000 Р
Выручка в год на M24	312 000 000 Р
Накопленный кэш на M24	66 646 017 Р
Самый большой минус по деньгам	-304 483 Р
Первый плюсовой месяц (прибыль > расходов)	M6
Когда вернули вложенные деньги	M8
Маркетинг суммарно за 24 мес	4 700 000 Р
Инфра (наша) суммарно за 24 мес	3 728 000 Р

10. Кеширование промптов

Anthropic / OpenAI: cached input reads = 10% of raw input. При 70% hit rate input стоимость падает на 63%.

AI-модель	Себест/сообщ без кеша	Себест/сообщ с кешем	Экономия %
DeepSeek V3.2	0.28 ₺	0.21 ₺	25.2%
Qwen 3 235B (self-hosted)	0.40 ₺	0.27 ₺	31.5%
Gemini 2.5 Flash	1.12 ₺	1.04 ₺	6.7%
Claude Haiku 4.5	2.40 ₺	2.15 ₺	10.5%
GigaChat 2 Pro	4.00 ₺	2.74 ₺	31.5%
GPT-4.1	4.00 ₺	3.50 ₺	12.6%
Claude Sonnet 4.6	7.20 ₺	6.44 ₺	10.5%
YandexGPT 5 Pro	9.60 ₺	7.58 ₺	21.0%

Эффективный множитель input при cache_hit=70%, cache_price=10%: 37.0% (экономия 63% на input).
Power-user Pro (1 200 msg на балансом миксе) получает примерно +6.5% gross margin от одного только кеша.

11. Свой AI-сервер Qwen 3 235B — когда окупится

Покупка железа 250к Р + текущие траты 120к/мес. Окупается с 500+ активных Pro клиентов.

Параметр	Значение
Покупка железа (1× A100 80GB или 2× RTX 4090)	250 000 Р
Текущие траты в месяц (электричество + охлаждение + износ за 5 лет)	120 000 Р
Производительность на 1 видеокарту	60 сообщений/час (8K токенов)
Часов работы в месяц	720 ч/мес
Сколько сообщений может обработать в месяц	43 200 сообщений
Себестоимость 1 сообщения на Qwen	2.78 Р
Доля задач, отправляемых на Qwen	30%

Когда окупится: зависит от количества активных Pro-клиентов (сравнение со стоимостью Sonnet через API)

Активных Pro	Сообщений/мес всего	Сообщений на Qwen	Если бы Sonnet, Р	Текущие на Qwen, Р	Экономия в мес	Месяцев до окупаемости
50	10 000 Р	3 000	21 600 Р	120 000 Р	-98 400 Р	никогда
100	20 000 Р	6 000	43 200 Р	120 000 Р	-76 800 Р	никогда
200	40 000 Р	12 000	86 400 Р	120 000 Р	-33 600 Р	никогда
500	100 000 Р	30 000	216 000 Р	120 000 Р	96 000 Р	2.6
1 000	200 000 Р	43 200	311 040 Р	120 000 Р	191 040 Р	1.3
2 000	400 000 Р	43 200	311 040 Р	120 000 Р	191 040 Р	1.3
5 000	1 000 000 Р	43 200	311 040 Р	120 000 Р	191 040 Р	1.3

До 200 клиентов: Qwen НЕ окупается — текущие траты 120к/мес больше экономии на API.
200–500 клиентов: 4–12 мес до окупаемости. Только если есть стратегические причины (закон 152-ФЗ, защита от блокировки).
500+ клиентов: 1–3 мес до окупаемости — однозначно стоит ставить.
По плану на M15: ~1 000 платящих → окупится на 4-м месяце после запуска Qwen.
Зачем вообще: закон 152-ФЗ из коробки + защита от блокировки западных AI + площадка для дообучения под Tilda/ЮKassa/1C.

12. Главные цифры за один взгляд

Если у вас 30 секунд на этот документ — вот ключевые числа.

1. Себестоимость одного сообщения: 0.28 → 9.60 ₽ в зависимости от AI-модели.
2. 200 сообщений в реальном миксе моделей стоят юзеру ≈ 1 000 ₽ = ровно Lite-кошелёк.
3. На каждом платящем клиенте мы зарабатываем в среднем 1 385 ₽/мес.
4. Базовые расходы — 30 К ₽/мес юрист. Founders сами разрабатывают (без зарплат). НАША инфра растёт от 8 К до 380 К/мес параллельно базе клиентов — это окупается ARPU.
5. С месяца 2 включается маркетинг 100 → 300 К/мес. Прибыль покрывает все расходы уже на месяце 6 при 380 платящих.
6. За 24 месяца модель выходит на 26 М ₽/мес выручки (~312 М в год) и +67 М ₽ на счёте.
7. Самый большой минус — всего ~305 К ₽ на месяце 5. Это в 8 раз меньше чем при найме разработчиков.
8. Инфра (наши сервера + БД + S3 + бэкапы + DDoS) суммарно за 24 мес — ~3.7 М ₽. Это 1.2% от 24-месячной выручки.
9. Запускаться можно без инвесторов и почти без денег: 30 К ₽ хватит на месяц 1, дальше выручка покрывает.

Источник: Token_Economics_v1.xlsx (15 листов с живыми формулами). Всё, что в PDF — это снапшот калькулятора. Меняй параметры в XLSX чтобы пересчитать.